



HANDLEIDING PRODUCTIE SV-BEVRAGING

Jorre Vannieuwenhuyze 

6 mei 2026 

1. ALGEMEEN

- Alle bestanden bevinden zich in de map

```
//WV162699/fs_kb_dkb/svr/Beveiligde_data_VSA/  
021_SVbevraging
```

Deze map is opgedeeld in drie submappen:

- 01_code: Bevat alle verwerkingscode voor de SV-bevraging. De map wordt gesynchroniseerd met GitHub: <https://github.com/vsa-datascience/SVsurvey.git>

Opmerking 1: naast scripts omvat deze map ook datasets die manueel worden aangemaakt om het productieproces overzichtelijk te houden – een werkwijze die binnen de VSA nog niet standaard is.

Opmerking 2: De codes bevatten nu ook processtappen die op termijn beter op algemeen niveau binnen de VSA door dedicated teams zouden moeten worden beheerd en uitgevoerd. Het gaat hierbij om de aanmaak van algemene programmeerfuncties, het beheer van het datamodel, en de aggregatie van demografische bevolkingsdata voor de berekening van de gewichten.

- 02_sourcedata: Opslagplaats voor alle aangeleverde ruwe datasets, onderverdeeld per versie (SV0001, SV0002, SV0003, ...). Elke versie bevat twee submappen:

- + 01_sample: Steekproefdata van Statbel
- + 02_survey: Enquêtedata van de veldwerkbureaus

Bij meerdere leveringen per versie is het aangeraden de bestanden verder onder te verdelen in mappen per aanleverdatum (formaat: YYYYMMDD).

Deze map bevat ook de submap Demobel-stock, met bevolkingsdata voor het berekenen van populatiestatistieken en weegfactoren voor de enquêterespondenten. Op termijn hoort deze data structureel thuis in //WV162699/fs_kb_dkb/svr/Beveiligde_data_VSA/011_Demografie, waarna Demobel-stock overbodig wordt.

- 03_deriveddata: Bevat alle tussentijdse, afgeleide bestanden die uitsluitend intern worden gebruikt tijdens de verwerking.
- Gedeelde data wordt weggeschreven naar twee aparte mappen:

- `//WV162699/fs_kb_dkb/svr/Beveiligde_data_VSA/998_Scientific_Use_Files`
Data voor intern gebruik binnen de VSA, raadpleegbaar door alle VSA-medewerkers maar niet bestemd voor externe publicatie. Voorbeelden zijn de Scientific Use Files (SUF's).
- `//WV162699/fs_kb_dkb/svr/Beveiligde_data_VSA/999_Public_Use_Files`
Data die open gepubliceerd mag worden en ook extern toegankelijk is. Hieronder vallen de Public Use Files (PUF's), zoals de bestanden met de officiële VOS'en.
- Mappen, labelcodes en dergelijke worden standaard in het Engels benoemd. Dit is een goede praktijk die de duurzaamheid en herbruikbaarheid van het werk ten goede komt.
- De meeste databestanden staan momenteel in `.xlsx`-formaat. Gezien de expertise binnen de VSA is dit het meest toegankelijke formaat voor inspectie en manuele aanpassingen, maar het is niet de meest efficiënte keuze. Formaten zoals `.csv`, `.parquet` of `.json` zijn stabiel en performanter. Het is aan het team om deze overstap in de toekomst te overwegen.
- Alle scripts zijn geschreven in R, maar kunnen in principe zonder veel moeite worden omgezet naar Python.
- Het verwerkingsproces start altijd door het RStudio-project `01_code/SVsurvey.Rproj` te openen. Dit stelt de working directory in op de map `01_code`, waarop alle paden in de code relatief zijn.
- Map `01_code/00_functions` bevat een soort R-package met functies voor de dataverwerking. Ze is opgebouwd volgens de algemene principes van een R-package. De functies zijn terug te vinden in sub-map R en werden gedocumenteerd via Roxygen2 in de code zelf.
- Deze documentatie werd aangemaakt in map `01_code/99_documentation`.

2. DATAMODEL

De eerste stap die we zetten is de opzet van een datamodel. We definiëren hiervoor eerst codelijsten. Nadien definiëren we de data structuur definities (DSD's) voor alle Internal, Scientific en Public Use files. In de DSD's wordt een overzicht van kolommen/variabelen gegeven en worden,

indien nodig, codelijsten aan deze kolommen gekoppeld. Hiermee volgen we de principes van SDMX.

Het datamodel wordt opgebouwd in map 01_code/01_data_model. Afgeleide codelijsten en data structuur definities worden weggeschreven naar de map 03_deriveddata/01_codelists. In principe wordt het beheer van het datamodel op termijn best overgedragen naar een dedicated datamodel-team, die werkt in map //WV162699/fs_kb_dkb/svr/Beveiligde_data_VSA/002_DataModel.

Het datamodel moet in principe ook enkel worden aangepast als er een nieuwe vraag wordt toegevoegd aan de SV-bevragingen, of als correcties worden gemaakt.

2.1. CODELIJSTEN

De map 01_data_model/01_code_lists bevat drie groepen codelijsten die worden aangemaakt via de codes in de map.

2.1.1. Algemene codelijsten

01_general_codelists: Dit zijn algemene codelijsten die geen speciale behandeling vragen. De aanmaak vraagt echter wel wat uitleg. Heel wat codelijsten zijn immers aan elkaar gelinkt. Eerste voorbeeld: Heel wat vragen in de SV-bevraging hebben identieke niet-substantiële categorieën zoals “Niet van toepassing” of “Ik weet niet/geen antwoord”. We zorgen ervoor dat de labelling van deze categorieën consistent blijft over de codelijsten heen. Tweede voorbeeld: Verschillende codelijsten zijn subsets van andere codelijsten. Voor demografische data hebben we bijvoorbeeld de codelijst “sex” met categorieën “man” en “vrouw”. Dit is een subset van de codelijst “srsex” (self reported sex) met categorieën “man”, “vrouw” en “X” zoals gebruikt in de vragenlijst van de SV-bevraging. Ook hier zorgen we best voor consistentie in labelling.

De general codelists worden daarom aangemaakt vanuit twee bestanden:

- input/code_list_values.xlsx bevat een overzicht van alle waarden die kunnen voorkomen op codelijsten. Dit overzicht bevat
 - een value: een gestandaardiseerde code die wordt gebruikt in datasets en voor scripting om referenties gemakkelijk te maken
 - een description_nl: Een nederlandstalige beschrijving van de waarde. Dit is louter als naslagwerk bedoeld en wordt verder niet gebruikt in de dataverwerking.

- `label_nl`, `label_fr`, `label_en`, ...: Dit zijn Nederlandse, Franse, Engelse, ...labels die worden gebruikt in output zoals public use files of gepubliceerde tabellen. Door deze labels in dit gecentraliseerd overzicht te bewaren zijn aanpassingen gemakkelijk door te voeren.

Eigenlijk is dit een soort conceptenlijst zoals gebruikt in SDMX, maar dan voor waarden op codelijsten. Mijn plan was een algemene conceptenlijst aan te leggen voor zowel variabelen als waarden, omdat bij dataverwerking waarden kunnen worden omgezet naar variabelen wanneer tabellen worden gepivoteerd.

- `input/code_list_skeletons.xlsx`: Dit bestand bevat de structuur van de codelijsten. Elk tabblad geeft een structuur van codelijsten die subsets van elkaar zijn. Het bevat kolommen
 - `value`: sleutel met bestand `code_list_values.xlsx`
 - `valuen`: Een numerieke waarde voor de `value`, zodat categorieën steeds consistent geordend kunnen worden
 - kolommen met aan te maken codelijsten. De kolomnaam is de naam van de codelijst die zal aangemaakt worden. Rijen met waarden `TRUE` bevatten de waarden die opgenomen worden in deze codelijst, rijen met waarde `FALSE` worden genegeerd in deze codelijst.

Script `create_general_code_lists.R` combineert beide bestanden en schrijft de codelijsten weg naar `03_deriveddata/01_codelists`. Hierin komen alle aparte codelijsten te staan als `.xlsx`-bestanden. Elke codelijst bevat de kolommen:

- `valuen` en `value`
- de labels in verschillende talen
- de `values` van codelijsten die een subset zijn. Dit kan gebruikt worden als mapping tijdens de dataverwerking. Zo kan bijvoorbeeld voor de SV-bevraging een variabele met niet-substantiële categorieën (“Weet niet/geen antwoord” etc.) snel gemapt worden naar een codelijst zonder die niet-substantiële categorieën op een consistente manier.

2.1.2. Specifiekere codelijsten

Naast de algemene codelijsten zijn er ook nog heel wat codelijsten met specifiekere verwerking. Deze worden in de andere mappen aangemaakt.

NIS codes

Script `02_NIS_codes/create_code_lists_NIScodes.R` maakt codelijsten aan voor de NIS-codes voor gewesten, provincies, arrondissementen, gemeenten en deelgemeenten. Dit gebeurt op basis van de bestanden van Statbel die kunnen worden gedownload van <https://statbel.fgov.be/nl/over-statbel/methodologie/classificaties/geografie>, terug te vinden in map `02_NIS_codes/input`. Er worden verschillende versies van codelijsten weggeschreven voor de jaren 1983, 1995, 2019 en 2025. In deze jaren was er immers steeds een wijziging in de NIS-codering aangebracht. De codelijsten worden ook steeds aangemaakt voor de verschillende niveau's:

- 0 = het rijk
- 1 = gewesten
- 2 = provincies
- 3 = arrondissementen
- 4 = gemeenten
- 5 = deelgemeenten

In map `03_deriveddata/01_codelists` vind je ze terug als `cl_refnisVERSIONlv1NIVEAU.xlsx`. Daarnaast wordt er voor elke versie een algemene codelijst aangemaakt die de verschillende niveau's combineert `cl_refnisVERSION.xlsx`. In elke codelijst ga je opnieuw kolommen vinden om te mappen naar andere versies en niveau's, bijvoorbeeld om gemeenten om te zetten naar provincies.

Landencodes

Landen worden op verschillende manieren gecodeerd en ingedeeld. Het script `03_country_codes/create_code_lists_countries.R` creëert deze codelijsten. Het gaat hierbij om een indeling volgens ISO2, ISO3, de NIS-codes, en indelingen naar landengroepen.

Andere codelijsten

Voor de SV-bevraging worden niet al deze codelijsten gebruikt. Voor de NIS-codes worden enkel codes gebruikt op gemeenteniveau. Bij de landencodes worden enkel de NIS-landencodes gebruikt. De aanmaak van deze codelijsten werden echter al ontwikkeld binnen het transitietraject voor de VSA-breed. Ik heb dus gewoon deze programma's gekopieerd naar de SV-bevraging.

Daarnaast werkte ik ook al aan andere codelijsten. De programma's hiervoor zijn te vinden in de map `//WV162699/fs_kb_dkb/svr/Beveiligde_`

data_VSA/002_DataModel/00_Code, maar deze vragen nog verdere verwerking. Het gaat hierbij om de creatie van codelijsten voor NIS-codes van de statistische sectoren, voor tijdsvariabelen, voor postcodes en voor andere variabelen van demobel stand van de bevolking. In deze aanmaak zitten geen codelijsten nuttig voor de SV-bevraging maar kunnen wel gebruikt worden later voor andere dataverwerkingsprocessen, wanneer het beheer van de datamodellen gecentraliseerd worden bij één team.

Verdere opermerkingen

- Script `create_code_lists.R` creëert alle codelijsten in `03_deriveddata/01_codelists` van een clean sheet door alle andere scripts te laten lopen in de submappen. Het bevat dus geen code die zelf codelijsten aanmaakt, maar roept alle andere scripts aan. Het voordeel van dit script is dat het eerst de map `03_deriveddata/01_codelists` verwijdt om nadien weer aan te maken.
- In de scripts mankeren nog checks op consistenties binnen en tussen codelijsten. Bijvoorbeeld, zijn alle namen uniek, heeft elke codelijst tenminste een `value` en `label_nl` kolom, zijn de `values` en numerieke `values` uniek, ...Dit kan nog toegevoegd worden.

2.2. DATA STRUCTUUR DEFINITIES

Nadat de codelijsten zijn aangemaakt, kan de data structuur definitie (DSD) worden aangemaakt. In de DSD worden alle kolommen/variabelen van een dataset op gelijst, ook wel concepten genoemd, en eventueel gekoppeld aan codelijsten volgens de principes van SDMX. Op deze manier vormt de DSD de basis voor de sterschema's in onze database. Wij gaan echter een stap verder en voegen ook andere criteria toe voor de concepten, bijvoorbeeld minimum en maximum waarden voor numerieke concepten, of regular expressions voor karakteriële concepten.

De strategie is dat er één grote centrale DSD wordt aangemaakt met een overzicht van alle variabelen in alle mogelijke datasets en datatabellen samen met de bijhorende criteria. Voor specifieke datasets zoals de public use files of de datatabellen met VOS-cijfers worden de gepaste concepten/variabelen geselecteerd en criteria eventueel verfijnd.

De aanmaak van de DSD start van bestand `01_code/01_data_model/02_DSD/dsd_variables.xlsx`. Deze spreadsheet start van een overzicht van alle mogelijke variabelen. Het bevat volgende kolommen:

- `concept_id`: Unieke identificatienaam van de variabele (unieke sleutel / variabelenaam).

- `description_nl`: Uitgebreide inhoudelijke beschrijving van de variabele in het Nederlands, dit wordt verder niet gebruikt in de data-verwerking.
- `label_nl`: Korte, publiekgerichte label van de variabele in het Nederlands.
- `label_fr`: Korte label van de variabele in het Frans.
- `label_en`: Korte label van de variabele in het Engels.
- `format`: Datatype of opslagformaat van de variabele, heeft enkel waarden `character`, `codelist`, `integer`, `numeric` of `date`.
- `codelist`: Verwijzing naar de gebruikte codelijst indien de variabele gecodeerde waarden bevat, de codelijst moet terug te vinden zijn in `03_deriveddata/01_codelists`.
- `regex`: Reguliere expressie waaraan de waarden van de variabele moeten voldoen (validatieregel), enkel voor karakteriële variabelen.
- `min`: Minimale toegelaten waarde (voor numerieke variabelen).
- `max`: Maximale toegelaten waarde (voor numerieke variabelen).
- `missing_values`: Logisch, is `TRUE` als de variabele missende waarden mag bevatten en `FALSE` als er geen missende waarden mogen voorkomen.
- `complete`: Indicator die aangeeft of er in een dataset verwacht wordt dat alle mogelijke waarden voorkomen. Dit wordt gebruikt voor de aanmaak van bijvoorbeeld VOS-tabellen. Als je in zo'n tabel bijvoorbeeld voor elke gemeente een waarde verwacht, moet `complete=TRUE` voor variabele `refnisXXXXlv4`.

Script `01_code/01_data_model/02_DSD/check_and_publish_dsd.R` kopieert `dsd_variables.xlsx` naar `03_deriveddata/02_DSD/dsd.xlsx`, maar voert eerst verschillende checks uit zodat er geen fouten in de DSD kunnen voorkomen. Voorbeelden van zo'n checks zijn nazicht dat alle concept ID's uniek zijn, dat voor elk concept met codelijst een geldige verwijzing gebeurt naar een codelijst in `03_deriveddata/01_codelists`, dat de regular expressions valide zijn, etc. Het bestand `03_deriveddata/02_DSD/dsd.xlsx` wordt dus gebruikt voor de verdere dataverwerking.

2.3. OPMERKINGEN

Mijn strategie was dat in de dataverwerking de DSD verder verfijnd kan worden AANVULLEN

3. POPULATIE INFORMATIE

De tweede stap is de aggregatie van bevolkingsstatistieken voor de berekening van de poststratificatiegewichten in de SV-bevraging. Dit gebeurt op de stock bevolkingsdata. Dit is eigenlijk een proces dat op een gestructureerde manier zou moeten worden opgenomen door de demografen (of de data engineers verantwoordelijk voor de demografiedataprocessen) in folder `//WV162699/fs_kb_dkb/svr/Beveiligde_data_VSA/011_Demografie`. Waarna de scripts voor de verwerking van de SV-bevraging deze geaggregeerde data daar gewoon kunnen ophalen.

Aggregatie van de bevolkingsdata gebeurt per jaar en niet per editie van de SV-bevraging, aangezien de bevolkingsdata per jaar wordt opgeleverd. Vandaar dat dit een aparte stap is.

De aggregatie gebeurt op basis van de demografische stock data. Deze worden in bewaard in map `021_SVbevraging/02_sourcedata/Demobel-stock`. Steeds in sav-formaat. Gebruik steeds dezelfde naam `"stock_YYYY.sav"` want de scripts halen deze bestanden automatisch op! Als een andere naam wordt gekozen zullen de scripts niet werken. Vraag steeds de demografen om de databestanden aan te leveren, of dus op termijn om zelf de aggregaties gestandaardiseerd te voorzien waardoor deze map met dubbele databewaring kan verwijderd worden.

De aggregatie wordt gedaan via de scripts in map `01_code/02_population_data`. Er is een script per jaar maar deze roepen enkel de functie `SVsurvey_aggregate_population()` uit `01_code/00_functions/R` aan die automatisch de geaggregeerde cijfers wegschrijft naar `03_deriveddata/03_aggregated_population_data`.

4. DATAVERWERKING

De volgende stap is om voor elke editie de data te verwerken. Dit gebeurt in map `01_code/03_process_editions` waarin je een scriptmap vindt per editie en een map voor algemene metadata. De verwerking van de data gebeurt in verschillende stappen.

4.1. METADATA

Op de eerste plaats wordt metadata op een overzichtelijke manier bewaard in databestanden in plaats van programmascripts. Deze metadata

moet doorheen het verwerkingsproces en bij elke editie actief worden aangevuld (anders krijg je wel een foutmelding die aangeeft dat het moet worden aangevuld). Dit zijn de databestanden die worden gebruikt:

- 01_code/03_process_editions/Metadata/Editions.xlsx: Geeft een overzicht van de verschillende edities van de SV-bevraging.
- 01_code/03_process_editions/Metadata/Mailings.xlsx: Geeft een overzicht van alle contactpogingen voor elke veldwerk-periode binnen de SV-bevraging.
- 01_code/03_process_editions/Metadata/Sports.xlsx: Bevat de lijst met sporten die worden gecodeerd door Tina. Aan deze lijst kan er niets worden veranderd, behalve sporten worden toegevoegd. Ze koppelt een gestandaardiseerde beschrijving aan een nummer.
- 01_code/03_process_editions/Metadata/Questions.xlsx: Dit bevat een overzicht van alle vragen die worden gesteld in de SV-bevraging. Het koppelt de `concept_id`'s uit het datamodel aan specifieke vraagverwoordingen. Die vraagverwoording is terug te vinden in de kolommen `question` en `question_item`. Daarnaast bevat het ook informatie over de vragenlijstmodule waarin de vraag wordt gesteld in kolom `question_module`. Dit bestand kan gebruikt worden om kleine wijzigingen in vraagverwoording te registreren waarbij geen grote resultaatbreuken worden verwacht. Hiervoor maak je gebruik van de kolom `from_surv_id`. In deze kolom staat de versie van de SV-bevraging vanaf wanneer een bepaalde vraagverwoording werd gebruikt. Bijvoorbeeld, in de 11de editie veranderde de vraagverwoording voor de vragen rond sportparticipatie van "Welke sporten beoefent u momenteel?" naar "Welke sporten heeft u de voorbije 12 maanden beoefend?". Voor elk van deze vragen zal je in de dataset twee rijen vinden, één voor de eerste verwoording vanaf editie SV0001 en één voor de tweede verwoording vanaf editie SV0011.

Opgelet, bij grote wijzigingen in vraagverwoording waarbij een grote impact wordt verwacht op de resultaten, moet er per definitie een nieuw concept worden gedefinieerd in het datamodel. Er dient ook nog nagekeken te worden of alle wijzigingen in vraagverwoordingen van SV0001 tot SV0015 in dit bestand geregistreerd staan.

Meer over het gebruik van deze dataset staat in paragraaf 4.2 en 4.3.

- 01_code/03_process_editions/Metadata/Answers.xlsx: Dit bevat alle antwoordverwoordingen die worden getoond in de vragen-

lijst van de SV-bevragingen en in principe worden gebruikt als value label in de aangeleverde data. De value label wordt gekoppeld aan de codelijsten via de unieke value. Net zoals bij Questions.xlsx kan deze dataset gebruikt worden om kleine wijzigingen in verwoordingen te documenteren. Dit gebeurt op dezelfde manier als bij de vragen via de kolom from_surv_id. Bij de aanmaak van de codeboeken en in de cleaning wordt steeds gekeken naar de meest recente value label door de hoogst mogelijke editie te nemen onder from_surv_id die lager is dan de gevraagde editie.

Opnieuw, bij grote wijzigingen in antwoordverwoording waarbij een grote impact wordt verwacht op de resultaten, moet er per definitie een nieuw concept worden gedefinieerd in het datamodel. Er dient ook nog nagekeken te worden of alle wijzigingen in vraagverwoordingen van SV0001 tot SV0015 in dit bestand geregistreerd staan.

Meer over het gebruik van deze dataset staat in paragraaf 4.2 en 4.3.

- 01_code/03_process_editions/Metadata/Variables_for_VOS.xlsx: Deze dataset bevat alle afgeleide variabelen die worden gemaakt voor een tussenliggende analysedataset met het oog op de aanmaak van de openbare statistieken (proporties of gemiddelden). Het gaat voornamelijk over variabelen die worden gedichotomiseerd voor de cijfers op de cijferpagina's (deze eindigen doorgaans op _dich), variabelen waarbij de niet-substantiële categorieën worden verwijderd (deze eindigen doorgaans op _subst), of variabelen die numeriek worden gemaakt om het gemiddelde te berekenen (deze eindigen doorgaans op _n). Meer over het gebruik van deze dataset staat in paragraaf 4.4. De dataset bestaat uit
 - VOSn: de numerieke code van de VOS waarvoor de variabele wordt gebruikt (! sommige variabelen worden gebruikt in meerdere VOS'en en komen dus meerdere keren voor in het bestand)
 - VOSname: de naam van de VOS waarvoor de variabele wordt gebruikt (! sommige variabelen worden gebruikt in meerdere VOS'en en komen dus meerdere keren voor in het bestand)
 - varname: de variabelenaam
 - varlabel: de label van de variabele, om over te nemen in opgeleverde datasets, zodat collega's weten wat de variabele inhoudelijk betekent
 - calc_p_value: Dit was een flag variabele om aan te geven of er voor deze variabele *p*-waarden moesten worden bere-

kend wanneer ze gekruist worden met covariaten. Deze kolom wordt niet meer gebruikt, ik heb deze delen in de scripts uitgecomment. Binnen de VSA werden p -waarden op een niet zo koosjere manier gebruikt, namelijk om binair te bepalen of er een samenhang was tussen twee variabelen of niet zonder te kijken naar effectgroottes en inhoudelijke interpretaties. Naast p -waarden worden ook betrouwbaarheidsintervallen berekend en weergegeven. Ik adviseer dus om niet te veel aandacht nog te besteden aan p -waarden, zolang de statistische expertise van het team niet wordt verhoogd.

- type: Deze kolom vertelt welke statistiek moet worden berekend op de variabele:
 - + percentage: een percentage voor dichotome logische variabelen (TRUE/FALSE).
 - + multinom: alle percentages voor alle categorieën van de variabele.
 - + mean: het gemiddelde voor numerieke variabelen.
- description: een beschrijving van de statistieken die worden berekend. Eveneens om over te nemen in opgeleverde datasets, zodat collega's weten wat de cijfers in datasets betekenen.

De kolomnamen van dit bestand kunnen nog beter. Op langere termijn zou deze dataset volgens mij echter kunnen verdwijnen, meer hierover bij de bespreking van de berekening van de VOS'en in paragraaf 4.4

4.2. AANMAAK CODEBOEK

De eerste stap in de verwerking van een SV-bevraging is de aanmaak van het codeboek. Dit codeboek wordt verstuurd naar het veldwerkbureau. Dit zijn de stappen:

1. Als de vraagverwoording en antwoordverwoording worden aangepast (enkel bij minimale tekstuele wijzigingen, anders moet een nieuw concept worden gedefinieerd), moeten bestanden
01_code/03_process_editions/Metadata/Questions.xlsx
en
01_code/03_process_editions/Metadata/Answers.xlsx
worden bijgewerkt. In principe zouden dit soort wijzigingen maar heel sporadisch mogen gebeuren.

2. Zorg ervoor dat het bestand

01_code/03_process_editions/SVXXXX/input/SVXXXX_variables_survey.xlsx

klaarstaat. Dit bestand geeft een overzicht van alle variabelen die worden verwacht te worden opgeleverd door het veldwerkbureau en welke naam moet worden gebruikt voor elke variabele (kolom variable). De volgorde van deze variabelen is belangrijk, want deze wordt integraal overgenomen in het codeboek. Het bestand geeft ook aan hoe die variabele zal worden omgezet naar een concept (gestandaardiseerde variabele) in de gekuiste data (kolom concept_id). Voor elke variabele moet er een concept gedefinieerd zijn, anders krijg je foutmeldingen als je de scripts laat lopen.

3. Maak het script

01_code/03_process_editions/SVXXXX/01_create_codebook_SVXXXX.R

aan (kopieer dit uit een vorige editie en pas de editie aan). In dit script wordt de functie SVsurvey_create_codebook() aangeroepen. Deze functie laadt het bestand

01_code/03_process_editions/SVXXXX/input/SVXXXX_variables_survey.xlsx

in, koppelt dit via concept_id aan de juiste vraagverwoording, variable labels, codelijsten, en antwoordverwoordingen uit de Data Structuur Definitie, Questions.xlsx en Answers.xlsx, compileert het codeboek, en schrijft dit weg naar het bestand

03_deriveddata/04_Codebooks/Codebook_SVXXXX.xlsx. Klaar!

4.3. CLEANING DATA

Nadat het codeboek is doorgestuurd naar het veldwerkbureau, en dat bureau het veldwerk heeft uitgevoerd en de data heeft opgeleverd, kan de data worden verwerkt. De eerste stap daarin is de validatie en cleaning van de opgeleverde data. Deze stappen neem je daarvoor:

1. De steekproefdata moet klaar staan in map

02_sourcedata/SVXXXX/01_sample

2. Zorg ervoor dat het bestand

01_code/03_process_editions/SVXXXX/input/SVXXXX_variables_sample.xlsx

klaarstaat. Dit bestand geeft een overzicht van alle variabelen die worden gebruikt in de sample data (kolom variable) en die worden overgezet naar een gestandaardiseerde variabele in de gekuiste data. De variabelenamen in kolom variable moeten overeenkomen met kolomnamen in de sample data (!hoofdletter-

gevoelig). Het bestand geeft ook aan hoe die variabele zal worden genoemd in de gekuiste data (kolom `concept_id`). Voor elke gebruikte variabele moet er een concept gedefinieerd zijn, anders krijg je foutmeldingen als je de scripts laat lopen. Variabelen die niet worden gebruikt voor de cleaning moeten niet in dit bestand worden opgenomen.

3. De responsdata moet klaarstaan in map

`02_sourcedata/SVXXXX/02_survey`

Advies, als er verschillende versie binnenkomen, maak dan submappen aan met de datum als mapnaam in “YYYYMMDD”

4. Zorg ervoor dat het bestand

`01_code/03_process_editions/SVXXXX/input/SVXXXX_variables_survey.xlsx`

klaarstaat. Dit bestand geeft een overzicht van alle variabelen die worden verwacht te worden opgeleverd door het veldwerkbureau en welke naam moet worden gebruikt voor elke variabele (kolom `variable`). De variabelenamen in kolom `variable` moeten overeenkomen met kolomnamen in de survey data (!hoofdlettergevoelig). Het bestand geeft ook aan hoe die variabele zal worden omgezet naar een concept (gestandaardiseerde variabele) in de gekuiste data (kolom `concept_id`). Voor elke variabele moet er een concept gedefinieerd zijn, anders krijg je foutmeldingen als je de scripts laat lopen. Variabelen die niet worden gebruikt voor de cleaning moeten niet in dit bestand worden opgenomen.

5. Maak de code

`01_code\03_process_editions\SVXXXX\02_clean_data_SV0001.R`

om de data manueel te cleanen, en vervolgens structureel. Deze code bevat over het algemeen volgende blokken:

- a. Inladen en klaarzetten van de steekproefdata. Zorg hierbij ervoor dat
 - de data nog enkel de variabelen bevatten die worden gebruikt voor de cleaning met de juiste naam (dus de variabelen opgelijst in `SVXXXX_variables_sample.xlsx`).
 - alle variabelen voldoen aan de evaluatie criteria in de DSD (juiste type [numeriek, character, codebook,...], juiste codebook-waarden hebben, ...)
- b. Inladen en klaarzetten van de surveydata. Zorg hierbij ervoor dat:

- als er met .sav bestanden wordt gewerkt, de variable-labels juist zijn zoals in het codebook. Via de functie `SVsurvey_labelled_2_tibble` wordt de data automatisch opgeschoond maar worden de variable labels ook nagekeken. Het tweede argument in deze functie laat toe correcte labels te voorzien als een named vector.
 - dat correctie op basis van open tekstvakken worden doorgevoerd. Hiervoor zet Tina het bestand
`01_code\03_process_editions\SVXXXX\input\SV0001_herocoding_obv_tekstvakken.xlsx`
 klaar. Je kan de correcties snel implementeren via de `coalesce_join()` functie.
 - Als de sportvragen aanwezig zijn, dat deze worden gecodeerd. Tina documenteert de hercodering in bestand
`01_code\03_process_editions\SVXXXX\input\SV0014_herocoding_sport.xlsx`
 op basis van
`01_code\03_process_editions\Metadata\Sports.xlsx`.
 Sporten 1 tot 15 worden bevraagd via selectievragen en moeten eventueel worden gecorigeerd op basis van de open antwoordvakken net zoals de andere variabelen in het bestand. Sporten 16-...worden karakterieel opgeslagen in variabele `spt_othx`, als een semicolon-separated (;) lijst. Zorg hierbij er zeker voor dat de gestandaardiseerde sportnamen uit `Sports.xlsx` worden gebruikt.
 - de data nog enkel de variabelen bevatten die worden gebruikt voor de cleaning met de juiste naam (dus de variabelen opgelijst in `SVXXXX_variables_sample.xlsx`).
 - alle variabelen voldoen aan de evaluatiecriteria in de DSD (juiste type [numeriek, character, codebook,...], juiste codebook-waarden hebben, ...)
- c. Laat de `SVsurvey_clean_data()` lopen op de steekproef en survey-data. Deze functie voert alle checks uit op consistenties en zal errors geven als iets niet juist staat. Nadien voert het de gestandaardiseerde data-cleaning uit (zoals afgeleide variabelen berekenen, gewichten berekenen, etc.) en schrijft de data weg naar
`03_deriveddata\05_Cleaned_data` als .parquet-bestanden.

Als er iets niet in orde is, zal je foutmeldingen krijgen. Wat als je errors krijgt? Dit kan meerdere oorzaken hebben maar ook meerdere oplossingen:

- Een waarde in de steekproefdata komt niet voor in een code-lijst. Dit kan zowel een fout zijn in het databestand als in de code-lijst zelf. Dat laatste zou in principe niet mogen voorkomen, maar de praktijk leert dat bijvoorbeeld de code-lijsten met landencodes van Statbel (`cl_countryNIS`) niet compleet zijn (o.a. gebruikt voor geboorteland en nationaliteit). Je kan dan ofwel de steekproef-/survey data aanpassen manueel, of je kan de code-lijsten updaten. Dat laatste is uiteraard duurzamer zolang je zeker bent dat de code consistent door Statbel wordt gebruikt. Als je de data zelf corrigeert gebruik dan functies zoals `dplyr::replace_values()` in een `dplyr::mutate()` stap.
- Een waarde in de surveydata komt niet voor in een code-lijst. Dit kan zowel een fout zijn in het databestand als in de code-lijst zelf, maar hier ook in bestand in het bestand `Answers.xlsx`. Je kan dezelfde oplossing kiezen als het punt hiervoor, of je kan bestand `Answers.xlsx` aanpassen. Pas `Answers.xlsx` echter enkel aan als het echt om een gevraagde kleine wijziging in vraagverwoording gaat, want deze wijzigingen zullen meegenomen worden naar de volgende edities. Als het veldwerkbureau gewoon een verkeerde waarde heeft aangeleverd, vervang je dit best manueel via functies zoals `dplyr::replace_values()` in een `dplyr::mutate()` stap.
- Variabelenamen zijn fout. Dan heb je opnieuw twee opties. Ofwel verander je de variabelenaam manueel in de code, ofwel corrigeer je de variabelenaam in de bestanden `SVXXXX_variables_sample.xlsx` of `SVXXXX_variables_survey.xlsx`. Die laatste optie is natuurlijk veel eleganter.

4.4. AANMAAK VOS'EN

4.5. CREATIE PUBLIC EN SCIENTIFIC USE FILES

5. KLAARZETTEN TABELLEN CIJFERPAGINA'S

6. NIEUWE VRAGEN

Wat moet er gebeuren als er nieuwe vragen worden toegevoegd aan de SV-bevraging

1. codelijst aanmaken
2. concept toevoegen aan dsd
3. vraagverwoording toevoegen aan Questions.xlsx
4. antwoordverwoording toevoegen aan Answers.xlsx
5. variabele mee opnemen in cleaning, ze moet dus ook staan in het overzicht SVXXXX_variables_survey.xlsx
6. Als er speciale bewerkingen tijdens de cleaning moeten worden uitgevoerd, moet dit opgenomen worden in SVsurvey_clean_data.R
7. analyse van de variable moet worden toegevoegd aan de SVsurvey_create_VOS.R
8. Voeg de variabele toe aan bestand voor PUF en SUF
9. de aanmaak van een tabel voor DataWrapper moet worden toegevoegd